

應用LSTM於再生能源發電預測-以太陽能為例

翁政雄

國立勤益科技大學資訊管理系教授

ch.weng@ncut.edu.tw

張定原

國立勤益科技大學資訊管理系教授

c07408@ncut.edu.tw

呂育嘉*

國立勤益科技大學資訊管理系

louis880625@gmail.com

摘要

本研究運用四種深度學習技術(RNN、LSTM、Stack LSTM、Bi-LSTM)於太陽能發電量預測，期能協助電力公司預先了解當日發電量，進而有效地進行電力調度與精準掌握即時的發電量資訊，以減少電能的損失與發電成本的消耗。實驗部分，本研究採用Alice Springs, Australia(澳大利亞愛麗絲泉)所收集的太陽能資料集，做為四種深度學習模型效能評估資料集，並且使用平均絕對誤差(MAE)、均方誤差(MSE)、均方根誤差(RMSE)等R平方(R^2)等指標用以衡量4種深度學習技術之預測效能。實驗結果顯示：(1)RMSE及MSE指標：Stack-LSTM模型最佳；Bi-LSTM模型次之；LSTM模型第三；RNN最差。(2)MAE指標：Bi-LSTM模型最佳；Stack-LSTM模型次之；LSTM模型第三；RNN最差。(3) R^2 指標：RNN模型最佳；LSTM及Bi-LSTM模型次之；Stack-LSTM最差。

關鍵詞：深度學習、太陽能發電量、RNN、LSTM、Stack LSTM、Bi-LSTM

應用LSTM於再生能源發電預測-以太陽能為例

壹 緒論

根據國際再生能源署(IRENA)2022 年 4 月的報告，全球至 2021 年底再生能源發展狀況：第一為水力發電佔全球發電量 40%；第二為太陽能發電佔全球發電量 28%；第三風力發電佔全球發電量 27%；第四為地熱發電與海洋能源發電佔全球發電量 5%。在 2021 年全球再生能源電容量裝置增加了 9.1%，太陽能發電方面增加 19%，風力發電方面增加 13%，水力發電方面增加 2%，最後為地熱發電方面增加 8% (IRENA, 2022)。根據餘燼公司(ENBER)的統計，目前風力發電與太陽能發電佔全球發電的十分之一，在 2021 年統計太陽能發電增長 23%，風力發電則增長 14%，並且在 2021 年清潔能源共產出 38% 的電力，超過了煤炭發電的 36%，另外還提及為了使全球暖化的溫度保持在 1.5 度，風力發電與太陽能發電必須要在 2030 年前保持每年 20% 的成長率，此外 ENBER 的負責人提到為了因應全球暖化，故風力發電與太陽能發電在十年內，兩個主要能源都必須以閃電般的數度成長，才可避免全球暖化變嚴重(ENBER, 2022)。

台灣根據法務部全國法規資料庫(全國法規資料庫)在 2019 年對再生能源的規定，再生能源定義：「指太陽能、生質能、地熱能、海洋能、風力、非抽蓄式水力、國內一般廢棄物與一般事業廢棄物等直接利用或經處理所產生之能源，或其他經中央主管機關認定可永續利用之能源」(全國法規資料庫, 2019)。根據經濟部能源局再生能源資訊網(經濟部能源局)說明台灣在 2009 年 7 月公布施行「再生能源發展條例」，開始發展再生能源，此外台灣宣布再生能源發電預計在 2025 年達到發電量 1000 萬 KW 的目標，在 2019 年 5 月 1 日再次修正，考量國內再生能源開發潛力、國內經濟及電力供應穩定等因素，修訂 2025 年再生能源發電目標須達 2700 萬 KW 以上(經濟部能源局, 2021)。

根據行政院經濟部能源局(經濟部能源局)，109 年台灣所使用的能源有 97.8% 來自進口能源，2.2% 來自自產能源。此外依照再生能源使用率，可以分成以下幾種：第一為生質能與廢氣物發電，第二為太陽能發電，其次為水力以及風力發電(經濟部能源局, 2021)。臺灣電力系統因受限地理位置關係，因此對台灣而言電力系統需要具有安全性與穩定供應的能力。除此之外，太陽能在發電的過程中會受到日照強度、太陽能板功率等問題，進而影響到發電量的多寡(經濟部能源局, 2019)。再生能源具有間歇性、不易預測性的問題，使得再生能源有著如何併入電網與如何電力調度兩項最大挑戰，間歇性電力對電力系統的平衡與電網運轉會產生影響，輕者會導致系統頻率不穩定、區域電網電壓變動過大，嚴重時會導致輸電線路壅塞、區域電網電壓不穩定，此外若再生能源發電量瞬間減少太多，則可能導致系統頻率驟降，觸發低頻電驛動作卸載，影響供電的可靠度。因此，未來需要智慧電網調控電力與多元資源整合方式，以提升電網整體的效率、可調度性、可靠性和安全性(中工會, 2020)。

為了解決上述問題，本研究運用深度學習的循環神經網路(RNN)、長短期記憶(LSTM)、多層長短期記憶(Stack LSTM)及雙向長短期記憶(Bi-LSTM)等四種深度學習技術於預測太陽能發電量，期望所產出的預設模型能協助台灣電力公司預先了解當日發電量，進而有效地進行電力調度。其他章節規劃如下：第二章為文獻探討；第三章為研究方法；第四章為實驗，使用太陽能發電資料集，建立四種深度學習預測模型，進而評估四種深度學習模型之預測效能；第五章結論，探討本研究成果並說明未來研究展望。

貳 文獻探討

本研究採用循環神經網路(RNN)系列相關之機器學習方法進行太陽能發電預測，故文獻將依序回顧機器學習(Machine Learning, ML)、循環神經網路(Recurrent Neural Network, RNN)、長短期記憶(Long Short-Term Memory, LSTM)、多層長短期記憶(Stack Long Short-Term Memory, Stack LSTM)、雙向長短期記憶(Bidirectional Long Short-Term Memory, Bi-LSTM)等方法及其應用。

一、機器學習(Machine Learning, ML)

機器學習是指電腦模仿人類進行學習的行為，對已知知識進行分析並總結，得出無法直接觀察到的結論，它是現代人工智能領域的一個重要分支，基於數據的統計與學習，使得機器學習可以由觀察歷史數據並從中找出目前理論分析無法察覺到隱藏的規律，此技術可以應用於事物發展的預測和判斷(Liu et al., 2022)。機器學習以驚人的速度發展，因此吸引了大量的研究人員與業者，機器學習已成為最熱門的研究方向之一，另外機器學習在翻譯、語音識別、圖像識別、推薦系統等多個領域中都有重大的貢獻(Sun et al., 2020)。基本上機器學習可以分為三種類型：(1)監督式學習、(2)非監督式學習、(3)強化學習。其中，監督式學習主要用於分類，即是使用標記數據集訓練神經網路以學習輸入和輸出之間的相互關聯性。非監督式學習常用於特徵提取和神經網路的預訓練，使用未標記的數據集進行訓練。強化學習可以被視為機器學習(ML)的子領域，它探索基於觀察改進計劃和控制策略的技術(Xue & Chuah, 2018)。

二、循環神經網路(Recurrent Neural Network, RNN)

循環神經網路(RNN)是一種獨特類型的人工神經網路(ANN)，其循環可以感知輸入序列中的訊息，RNN 可以在不同層的神經元之間共享參數，從而在網路中形成循環，以提升預測結果。RNN 的循環架構可以對時間序列的資料進行預測，並在產生輸出的同時記住前一個時間的訊息。因此，RNN 模型具有記憶性(Rahman et al., 2021)。RNN 會根據前一個的單字預測已知系列中的下一個單字(Sivapriya et al., 2022)。RNN 能夠有效的將結構的提取出來，特別是對時間序列訊息和文字訊息的數據，皆能夠達到充分的應用。RNN 在語音識別、機器翻譯及時序分析方面也取得了突破。RNN 具有記憶的特點，可以將前一個時間的資訊記錄下來，然而由於數據對 RNN 的長期記憶，使得 RNN 容易在模型訓練

中，容易出現梯度消失和爆炸的問題(Wang et al., 2022)。

三、長短期記憶(Long Short-Term Memory, LSTM)

長短期記憶(LSTM)模型解決了 RNN 模型在梯度反向傳播過程中產生的梯度消失與爆炸的問題。LSTM 適用於處理與時間序列與高維度資訊的相關的問題，另外 RNN 在長期的時間序列預測中，RNN 仍然會陷入無法把握長期規律和捕捉長期特徵的困境，作為 RNN 的改進版本，LSTM 可以學習長期依賴訊息並避免產生梯度消失等問題(Yao, 2018)。LSTM 模型亦可用於序列分類、序列回歸和序列預測等應用上(Shi et al., 2022)。由於 LSTM 的參數很多與計算太複雜，因此 LSTM 需要花較多的時間成本進行訓練(Wang et al., 2022)。

四、多層長短期記憶(Stack Long Short-Term Memory, Stack LSTM)

多層長短期記憶(Stack Long Short-Term Memory, Stack LSTM)是由多個 LSTM 單元以垂直組裝而成的(Panja et al., 2022)。此外 Stack LSTM 模型也被廣泛使用，為了對應更高維度的時間序列的數據(Li et al., 2020)。Stack LSTM 是一種具有多個隱藏層的深度神經網路，此模型解決序列預測不穩定的問題(Zhang et al., 2020)。在某些情況下它比普通的 LSTM 有更好的效果更高的準確度(Pattana-Anake & Joseph, 2021)。

五、雙向長短期記憶(Bidirectional Long Short-Term Memory, Bi-LSTM)

雙向長短期記憶(Bi-LSTM)的想法來自雙向 RNN(Zhiyong et al., 2019)。Bi-LSTM 是 LSTM 其中一種變體，此模型在時間序列預測中是最常用的，此模型用於對過去和未來的數據進行預測(Pattana-Anake & Joseph, 2021)。另外 Bi-LSTM 模型在運作時，將時間訊息的資料用於兩個 LSTM 隱藏層，使資料之間以前向和後向的方式來回傳遞訊息進行運算(Panja et al., 2022)。此外有學者證明 Bi-LSTM 模型在音素與語音辨識領域，都明顯優於 LSTM(Zhiyong et al., 2019)。


參 研究方法

一、循環神經網路(Recurrent Neural Network, RNN)

循環神經網路(RNN)中的每個單元都有自己的隱藏狀態，它有著當前資料的上下文訊息，當向前移動到下一個單元時，來自前一個單元的隱藏狀態也會作為參考訊息被輸入被並且包括在內，這使得每個單元可以知道前面資料中的訊息，此外由於這些單元共享相同的權重的原因，使得 RNN 可以通過增加或減少權重，以處理和預測任意序列資料(Jiang et al., 2021)。RNN 由一系列相同的基本結構的模塊組成，傳統 RNN 的基本結構如圖一所示， x_t 是輸入向量， h_t 是 RNN 最終的輸出向量， \tanh 在 RNN 中是指一個隱藏狀態，RNN 數學表示法，如公式(1)所示。 \tanh 是一個名為雙曲正切的激活函數， b 為偏置向量， U 、 W 為

權重矩陣是隱藏狀態 h 和輸入 x 的參數，其每個時間對應的基本結構會具有相同的參數，即 b 、 U 、 W (Gao et al., 2019)。

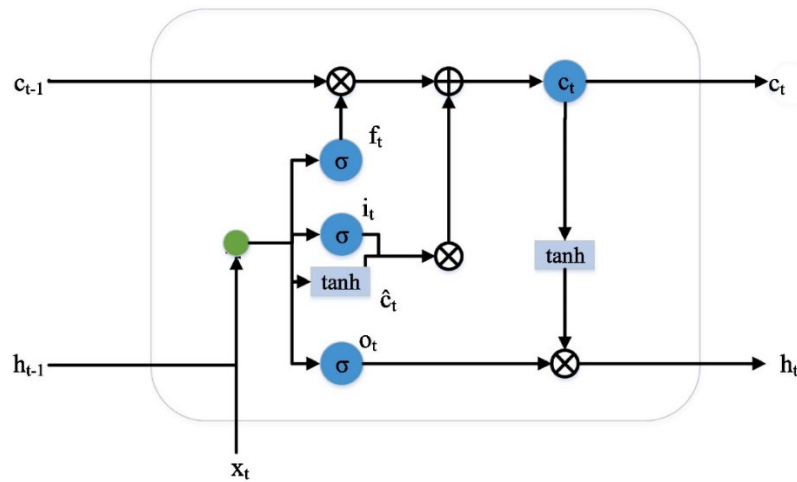
$$h_t = \tanh(Ux_t + Wh_{t-1} + b) \quad (1)$$



圖一、RNN 結構圖

二、長短期記憶(Long Short-Term Memory, LSTM)

長短期記憶(LSTM)是傳統循環神經網路的改良型，其增加了遺忘閥(Forget Gate)、輸入閥(Input Gate)和輸出閥(Output Gate)。在隱藏層運用這三個閥對歷史輸入、當前輸入和歷史輸出進行學習，從而實現記憶功能(Meng et al., 2021)。LSTM 單元的基本結構如圖二所示，其中 x_t 是輸入向量， $h_t(h_{t-1})$ 是 LSTM 單元在時間步 $t(t-1)$ 中的隱藏狀態， $c_t(c_{t-1})$ 是 LSTM 單元在時間步 $t(t-1)$ 中的單元狀態，LSTM 的結構表明，它的單元狀態(c_t)和隱藏狀態(h_t)轉移到下一個時間步 (Gao et al., 2019)。



圖二、LSTM 結構圖

在 LSTM 單元中是由三個閥(遺忘閥 f_t 、輸入閥 i_t 、輸出閥 o_t)的結構所組合而成，遺忘閥會判斷後一個記憶單元的訊息 C_{t-1} ，並選擇是否要遺忘此訊息，輸入閥用於確定當前存儲單元狀態中存儲的信息 C_t ，輸出閥影響當前狀態的輸出 h_t ， W_f 、 W_i 、 W_o 分別是遺忘閥、輸入閥、輸出閥的權重矩陣， b_f 、 b_i 、 b_o 分別是遺忘閥、輸入閥、輸出閥的偏差， \tilde{C}_t 是新的候選狀態， h_{t-1} 則是上一時刻 LSTM 單元的輸出值， x_t 是當前時刻的輸入， σ 是 Sigmoid 激活函數，其 LSTM 數學表示法，如公式(2)~(7)所示 (Meng et al., 2021)。

$$f_t = \sigma(W_f h_{t-1} + W_f x_t + b_f) \quad (2)$$

$$i_t = \sigma(W_i h_{t-1} + W_i x_t + b_i) \quad (3)$$

$$\tilde{C}_t = \text{than}(W_c h_{t-1} + W_c x_t + b_c) \quad (4)$$


$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (5)$$

$$o_t = \sigma(W_o h_{t-1} + W_o x_t + b_o) \quad (6)$$

$$h_t = o_f * \text{than}(C_t) \quad (7)$$

三、多層長短期記憶(Stack Long Short-Term Memory, Stack LSTM)

多層長短期記憶(Stack LSTM)由多個 LSTM 層組成，每個 LSTM 層包含多個連接的 LSTM 單元，通過多層長短期記憶可以使神經網路變得更深，因此可以在不同的時間序列上更好的學習輸入的時間序列的特徵(Zhang et al., 2020)。多層長短期記憶的結構圖如圖三所示，是由多個 LSTM 結合而成的模型，在 LSTM cell 可以從圖三得知此結構(Singh et al., 2015)。



圖三、Stack LSTM 結構圖改編於(Singh et al., 2015)

Du et al. (2017)提到 Stack LSTM 其公式與基本 LSTM 相同。LSTM 單元中是由三個閥(遺忘閥 f_t 、輸入閥 i_t 、輸出閥 o_t)的結構所組合而成，遺忘閥會判斷後一個記憶單元的訊息 C_{t-1} ，並選擇是否要遺忘此訊息，輸入閥用於確定當前存儲單元狀態中存儲的信息 C_t ，輸出閥影響當前狀態的輸出 h_t ， W_f 、 W_i 、 W_o 分別是遺忘閥、輸入閥、輸出閥的權重矩陣， b_f 、 b_i 、 b_o 分別是遺忘閥、輸入閥、輸出閥的偏差， \tilde{C}_t 是新的候選狀態， h_{t-1} 則是上一時刻 LSTM 單元的輸出值， x_i 是當前時刻的輸入， σ 是 Sigmoid 激活函數。Stack LSTM 的數學表示法，如公式(8)~(13)所示 (Meng et al., 2021)。

$$f_t = \sigma(W_f h_{t-1} + W_f x_t + b_f) \quad (8)$$

$$i_t = \sigma(W_i h_{t-1} + W_i x_t + b_i) \quad (9)$$

$$\tilde{C}_t = \text{than}(W_c h_{t-1} + W_c x_t + b_c) \quad (10)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (11)$$


$$o_t = \sigma(W_o h_{t-1} + W_o x_t + b_o) \quad (12)$$

$$h_t = o_f * \text{than}(C_t) \quad (13)$$

四、雙向長短期記憶(Bidirectional Long Short-Term Memory, Bi-LSTM)

雙向長短期記憶(Bi-LSTM)是長短期記憶(LSTM)的改良版本，與 LSTM 的不同之處在於，神經網路與過去和未來相連(Tuncera & Bolat, 2022)。Bi-LSTM 進行訓練時是採用同時訓練兩個 LSTM 的邏輯進行訓練(Dandil & Karaca, 2021)。

Bi-LSTM 考慮輸入過去和未來的值，最後組合輸出，採用此方式對於每一個數據，Bi-LSTM 的學習會受到過去和未來數據的影響(Tuncera & Bolat, 2022)。Bi-LSTM 的結構圖如四所示，可以看到使用兩個方向的 LSTM 單元由第一個 LSTM 通常為過去至未來 \vec{h}_0 、 \vec{c}_0 與第二個 LSTM 未來至過去 \overleftarrow{h}_0 、 \overleftarrow{c}_0 組合而成，可以在任何時間步長，將來自前向和後向單元的輸出連接起來，並產生單個輸出 y_t (Shah et al., 2021)。



圖四、Bi-LSTM 結構圖

Bi-LSTM 與 LSTM 神經網路具有相似的結構，並且包括兩層相互矛盾的 LSTM，Bi-LSTM 可以通過順序輸入向前和向後的運行，Bi-LSTM 的目標輸出可以表示順序輸入數據的前向和後向模式，前向層提供過去的信息，後向層提供未來的數據， \vec{h}_t 、 \overleftarrow{h}_t 分別表示為向後和向前方向的隱藏狀態， $W_{\leftarrow h}$ 、 $W_{\rightarrow h}$ 分別表示為隱藏層之間的相應權重，sigmoid 表示為激活函數， \bar{f}_t 、 \bar{m}_t 、 \bar{o}_t 分別表示為遺忘閥(Forget Gate)、輸入閥(Input Gate)和輸出閥(Output Gate)。Bi-LSTM 的數學表示法，如公式(14)~(19)所示 (Nguyen et al., 2021)。

$$y_t = W_{\leftarrow h} \vec{h}_t + W_{\rightarrow h} \overleftarrow{h}_t + b_y \quad (14)$$

$$\bar{f}_t = \text{sigmoid}(W_f * [\text{hid}_{t-1}, x_{t-1}] + b_{fg}) \quad (15)$$

$$\bar{m}_t = \text{sigmoid}(W_i * [\text{hid}_{t-1}, x_{t-1}] + b_{ig}) \quad (16)$$

$$\bar{o}_t = \text{sigmoid}(W_o * [\text{hid}_{t-1}, x_{t-1}] + b_{og}) \quad (17)$$

$$\bar{C}_t = \bar{f}_t * \bar{C}_{t-1} + \bar{m}_t * \tanh(W_c * [\text{hid}_{t-1}, x_{t-1}] + b_{gc}) \quad (18)$$

$$\overleftarrow{h}_t = \bar{o}_t * \tanh(\bar{C}_t) \quad (19)$$

肆 實驗

一、太陽能資料集

本研究採用由 Desert Knowledge Australia Solar Centre(澳大利亞沙漠知識太陽能中心, DKSC)網站所提供的太陽能資料集，太陽能資料收集地點位於 Alice Springs, Australia(澳大利亞愛麗絲泉)，資料集名稱為 1A Trina 10.5kW mono-Si

Dual 2009，此資料集紀錄 2014~2021 年間，以每五分鐘記錄一次數據，此資料集共有九個自變數 X 和一個應變數 Y，資料筆數為 834,199 筆(Khan et al., 2022)

二、衡量指標

均方根誤差(RMSE)和平均絕對誤差(MAE)是多種學科領域中所使用的兩種絕對誤差度量標準，例如機器學習、數據挖掘、時間序列分析、地球科學、大氣科學與生物科學等，這些指標主要用於擬合模型、驗證模型、模型比較和評估預測結果(Karunasingha, 2022)。均方誤差(MSE)、R 平方(R^2)與均方根誤差(RMSE)等這些度量標準經常應用於許多機器學習的效能評估 (Wood, 2020)。平均絕對誤差(MAE)、平均絕對百分比誤差(MAPE)與均方根誤差(RMSE)是最常用的三種測量模型的方法(Lai et al., 2020)。平均偏差誤差(MBE)、平均絕對誤差(MAE)、均方根誤差(RMSE)與 R 平方(R^2)這些是廣泛使用於衡量回歸模型性能的指標(Ser et al., 2022)。因此，本研究使用平均絕對誤差(MAE)、均方誤差(MSE)、均方根誤差(RMSE)與 R 平方(R^2)，用以衡量四種深度學習模型的預測效能。

三、平均絕對誤差(mean absolute error, MAE)

平均絕對誤差(MAE)是每個值之間的平均差異，透過計算預測值和實際值之間的差異所得出的值，作為判斷模型的標準(Sasser et al., 2022)。MAE 是估計值與相應觀測值之間的平均誤差的度量指標(Rahman et al., 2021)。MAE 是通過計算目標值和預測值之間的絕對差(Hussain et al., 2021)。如公式(20)所示，可以看到 y_i 代表實際輸出， \tilde{y}_i 代表預測值，n 表示預設樣本的數量(Goh et al., 2022)。MAE 的數值越低表明模型的學習效果越好，若數值越高則表示學習效果越不好，絕對值 MAE 是為了確保差值的最值為正(Shahid et al., 2021)。

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \tilde{y}_i| \quad (20)$$

四、均方誤差(Mean Square Error, MSE)

均方誤差(MSE)它是評估回歸問題最常見和最簡單的指標(Hussain et al., 2021)。MSE 是模型的實際值和估計值之間的差異(Khan et al., 2022)。如公式(21)所示，可以看到 y_i 代表實際輸出， \tilde{y}_i 代表預測值，n 表示預設樣本的數量(Goh et al., 2022)。MSE 為計算平方預測誤差，並在回歸線的每個點測量目標值與預測值之間的平方差，之後取這些值的平均值。MSE 的數值越低表明模型的學習效果越好，若數值越高則表示學習效果越不好(Hussain et al., 2021)。

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \tilde{y}_i)^2 \quad (21)$$

五、均方根誤差(Root Mean Square Error, RMSE)

均方根誤差(RMSE)它是 MSE 的平方根(Hussain et al., 2021)。RMSE 和 MAE 是與尺度相關的指標，用於計算實際值與預測值之間的總體差異(Ngarambe et al., 2020)。如公式(22)中可以看到 y_i 代表實際輸出， y_i^{\sim} 代表預測值 n 表示預設樣本的數量(Goh et al., 2022)。另外 RMSE 與 MSE 一樣，運算後結果的數值越低表明模型的學習效果越好，若數值越高則表示學習效果越不好(Hussain et al., 2021)。

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - y_i^{\sim})^2} \quad (22)$$

五、R 平方(R squared, R^2)

R 平方(R^2)表示目標變量的預測值和實際值線性相關的程度(Ser et al., 2022)。 R^2 表示因變量中可由自變量解釋的方差比例(Lai et al., 2020)。由公式(24)可以看到 y_i 代表實際值， y_i^{\wedge} 代表預測值， n 表示預設樣本的數量，在公式(25)中可以看到 y_i 代表實際值， y_i^{-} 代表平均實際值， n 表示預設樣本的數量，在公式(23)中可以看到，將公式(24)、(25)算出後的數值以後，用 1 減去其數值，便可得到 R^2 的數值(Goh et al., 2022)。另外 R^2 的數值會介於 0~1 之間，若數值越接近 1 表示模型擬合效果良好，反之則越不良好(Shahid et al., 2021)。

$$R^2 = 1 - \frac{SSE}{SST} \quad (23)$$

$$SSE = \sum_{i=1}^n (y_i - y_i^{\wedge})^2 \quad (24)$$

$$SST = \sum_{i=1}^n (y_i - y_i^{-})^2 \quad (25)$$

六、實驗結果

實驗設計部分，本研究將太陽能資料集以 7:3 之比例進行切分，即前 70%為訓練集，後 30%為測試集，應用於循環神經網路(RNN)、長短期記憶(LSTM)、多層長短期記憶(Stack LSTM)、雙向長短期記憶(Bi-LSTM)四個模型。最後運用 RMSE、MSE、MAE 與 R^2 評估指標衡量四種深度學習模型之預測效能。

本研究所使用的循環神經網路(RNN)的結構及參數設定如下:(1)單層 RNN，設置 50 個神經元；(2)輸出層使用 1 個神經元；(3)訓練模型迭代為 150，批次大小為 2000。長短期記憶模型(LSTM)的結構及參數設定如下:(1)使用單層 LSTM，設置 150 個神經元；(2)輸出層採用 1 個神經元；(3)訓練模型迭代為 100，批次大小為 2000。多層長短期記憶模型(Stack LSTM)的結構及參數設定如下:(1)使用兩層 LSTM，第一層 LSTM 設置 150 個神經元，第二層 LSTM 設置 50 個神經元；(2)輸出層採用 1 個神經元；(3)訓練模型迭代為 150，批次大小為 500。雙向長短期記憶模型(Bi-LSTM)的結構及參數設定如下:(1)使用單層雙向 LSTM，設置 50 個神經元；(2)輸出層採用 1 個神經元；(3)訓練模型迭代為 150，批次大小為 500。

四種深度學習模型(RNN、LSTM、Stack LSTM 及 Bi-LSTM)之預測效能，

如表 1 所示。從各項評估指標可以看到本文應用的長短期記憶(LSTM)、多層長短期記憶(Stack LSTM)、雙向長短期記憶(Bi-LSTM)皆優於循環神經網路(RNN)，其中表現最好的模型為多層長短期記憶(Stack LSTM)，與循環神經網路(RNN)相比，RMSE、MSE、MAE 各別減少了 0.016、0.027、0.010， R^2 則增加了 0.003，其次表現好的模型為雙向長短期記憶(Bi-LSTM)，RMSE、MSE、MAE 各別減少了 0.007、0.013、0.020， R^2 則增加了 0.01，最後為長短期記憶(LSTM)，RMSE、MSE 各別減少了 0.004、0.006， R^2 則增加了 0.001。

表 1 太陽能發電評估指標之比較

方法	RMSE	MSE	MAE	R^2
RNN	0.857	0.735	0.267	0.911
LSTM	0.853	0.728	0.275	0.912
Stack LSTM	0.841	0.708	0.257	0.914
Bi-LSTM	0.850	0.722	0.247	0.912

伍 結論

近年來再生能源在全世界是一直進行研究的議題，在未來人們更加需要重視環境永續等問題，因此再生能源為全球重要的發展方向，但目前全球對於再生能源的掌握度仍然不足，尤其是台灣正處於能源轉型的發展階段，更加需要準確的預測模型，期輔助電力公司掌握即時的發電資訊，以防止陷入缺電與能源危機。本研究運用四種模型長短期記憶(LSTM)、多層長短期記憶(Stack LSTM)、雙向長短期記憶(Bi-LSTM)與循環神經網路(RNN)於太陽能發電預測。實驗結果顯示：三個模型(LSTM, Stack LSTM 及 Bi-LSTM)皆比循環神經網路(RNN)擁有更高的準確率，其中又以多層長短期記憶(Stack LSTM)為表現最好。其中，RMSE、MSE、MAE 各別減少了 0.016、0.027、0.010， R^2 則增加了 0.003，另外其次為雙向長短期記憶(Bi-LSTM)，最後為長短期記憶(LSTM)。未來研究方面，本研究希望能取得更多再生能源的數據集驗證模型的可靠性，除此之外，也希望能夠結合其他深度學習技術讓現有的預測模型更加準確。

參考文獻

- 中華民國經濟部能源局 (2021 年 12 月 24 日)。109 年能源供給概況。經濟部能源局。
- 陳沛清、林根勝、石昱郁、李昱萱、林秀琴、張桂瑜、梁愛倫、蔣雪芬、蔡琦姻 (2020 年 3 月)。大量再生能源併網的衝擊與電力調度因應策略。中國工程師學會會刊，93，77-88。
- 陳沛清、林根勝、石昱郁、李昱萱、林秀琴、張桂瑜、梁愛倫、蔣雪芬、蔡琦姻 (2020 年 3 月)。智慧電網發展與再生能源監控實務。中國工程師學會會刊，93，39-49。
- 經濟部 (2019 年 5 月 1 日)。再生能源發展條例。全國法規資料庫。
- 經濟部能源局 (2019 年 3 月 14 日)。太陽能發電量知識知多少。經濟部能源局能源資料庫。
- 經濟部能源局 (2021 年 6 月 2 日)。國際能源再生發展趨勢與政策。經濟部能源局再生能源資訊網。
- Dandil, E., & Karaca, S. (2021). Detection of pseudo brain tumors via stacked LSTM neural networks using MR spectroscopy signals. *Biocybernetics and Biomedical Engineering*, 41(1), 173-195.
- Du, X., Zhang, H., Nguyen, H. V., & Han, Z. (2017). Stacked LSTM Deep Learning Model for Traffic Prediction in Vehicle-to-Vehicle Communication. 2017 IEEE 86th Vehicular Technology Conference, 86, 1-5.
- Gao, S., Huang, H., Zhang, S., Han, J., Wang, G., Zhang, M., & Lin, Q. (2020). Short-term runoff prediction with GRU and LSTM networks without requiring time step optimization during sample generation. *Journal of Hydrology*, 589, 125188.
- Goh, H. H., He, R., Zhang, D., Liu, H., Dai, W., Lim, C. S., Kurniawan, T. A., Teo, K. T. K., & Goh, K. C. (2022). A multimodal approach to chaotic renewable energy prediction using meteorological and historical information. *Applied Soft Computing*, 118, 108487.
- Hussain, T., Ullah, F. U. M., Muhammad, K., Rho, S., Ullah, A., Hwang, E., Moon, J., & Baik, S. W. (2021). Smart and intelligent energy monitoring systems: A comprehensive literature survey and future research guidelines. *International Journal of Energy Research*, 45(3), 3590-3614.
- Jiang, A., Qin, Z., Faulder, D., T.Cladouhos, T., & Jafarpour, B. (2022). Recurrent neural networks for short-term and long-term prediction of geothermal reservoirs. *Geothermics*, 104, 102439.
- Jones, D. (2022, March 30). Record wind and solar - but also record coal and emissions. EMBER.

- Karunasingha, D. S. K. (2022). Root mean square error or mean absolute error? Use their ratio as well. *Information Sciences*, 585, 609-629.
- Khan, Z. A., Hussain, T., & Baik, S. W. (2022). Boosting energy harvesting via deep learning-based renewable power generation prediction. *Journal of King Saud University-Science*, 34(3), 101815.
- Khan, Z. A., Hussain, T., Haq, I. U., Ullah, F. U. M., & Baik, S. W. (2022). Towards efficient and effective renewable energy prediction via deep learning. *Energy Reports*, 8, 10230-10204.
- Lai, J. P., Chang, Y. M., Chen, C. H., & Pai, P. F. (2020). A Survey of Machine Learning Models in Renewable Energy Predictions. *Applied Sciences*, 10(17), 5975.
- Lebedys, A., Akande, D., Coënt, N., Elhassan, N., Escamilla, G., Arkhipova I. & Whiteman, A. (2022, April 11). Renewable capacity highlights. International Renewable Energy Agency.
- Li, J., Guo, F., Sivakumar, A., Dong, Y., & Krishnan, R. (2021). Transferability improvement in short-term traffic prediction using stacked LSTM network. *Transportation Research Part C: Emerging Technologies*, 124, 102977.
- Liu, Y., Chen, H., Zhang, L., Wu, X., & Wang, X. (2022). Energy consumption prediction and diagnosis of public buildings based on support vector machine learning: A case study in China. *Journal of Cleaner Production*, 272(1), 122542.
- Meng, A., Wang, P., Zhai, G., Zeng, C., Chen, S., Yang, X., & Yin, H. (2022). Electricity price forecasting with high penetration of renewable energy using attention-based LSTM network trained by crisscross optimization. *Energy*, 254(1), 124212.
- Ngarambe, J., Irakoze, A., Yun, G. Y., & Kim, G. (2020). Comparative Performance of Machine Learning Algorithms in the Prediction of Indoor Daylight Illuminances. *Sustainability*, 12(11), 4471.
- Nguyen, T. P., Yeh, C. T., Cho, M. Y., Chang, C. L., & Chen, M. J. (2022). Convolutional neural network bidirectional long short-term memory to online classify the distribution insulator leakage currents. *Electric Power Systems Research*, 208, 107923.
- Panja, P., Jia, W., & McPherson, B. (2022). Prediction of well performance in SACROC field using stacked Long Short-Term Memory (LSTM) network. *Expert Systems with Applications*, 205(1), 117670.
- Pattana-Anake, V. & Joseph, F. J. J. (2022). Hyper Parameter Optimization of Stack LSTM Based Regression for PM 2.5 Data in Bangkok. *International Conference on Business and Industrial Research*, 7, 13-17.
- Rahman, M. M., Shakeri, M., Tiong, S. K., Khatun, F., Amin, N., Pasupuleti, J., & Hasan, M. K. (2021). Prospective Methodologies in Hybrid Renewable Energy

- Systems for Energy Prediction Using Artificial Neural Networks. *Sustainability*, 13(4), 2393.
- Sasser, C., Yu, M., & Delgado, R. (2022). Improvement of wind power prediction from meteorological characterization with machine learning models. *Renewable Energy*, 183, 491-501.
- Ser, J. D., Casillas-Perez, D., Cornejo-Bueno, L., Prieto-Godino, L., Sanz-Justo, J., Casanova-Mateo, C., & Salcedo-Sanz, S. (2022). Randomization-based machine learning in renewable energy prediction problems: Critical literature review, new results and perspectives. *Applied Soft Computing*, 118, 108526.
- Shah, S. R. B., Chadha, G. S., Schwung, A., X. & Ding, S. (2021). A Sequence-to-Sequence Approach for Remaining Useful Lifetime Estimation Using Attention-augmented Bidirectional LSTM. *Intelligent Systems with Applications*, 10-11, 200049.
- Shahid, F., Zameer, A., & Muneeb, M. (2021). A novel genetic LSTM model for wind power forecast. *Energy*, 223, 120069.
- Shi, J., Peng, D., Peng, Z., Zhang, A., Goebel, K., & Wu, D. (2022). Planetary gearbox fault diagnosis using bidirectional-convolutional LSTM networks. *Mechanical Systems and Signal Processing*, 162, 107996.
- Singh, U., Chauhan, S., Krishnamachari, A., & Vig, L. (2015). Ensemble of deep long short term memory networks for labelling origin of replication sequences. *IEEE International Conference on Data Science and Advanced Analytics*, 2015, 1-7.
- Sivapriya, G., Praveen, V., Gowri, P., Saranya, S., Sweetha, S., & Shekar, K. (2022). Segmentation of Hard exudates for the detection of Diabetic Retinopathy with RNN based semantic features using fundus images. *Proceedings*, 64(1), 693-701.
- Sun, S., Cao, Z., Zhu, H., & Zhao, J. (2020). A Survey of Optimization Methods From a Machine Learning Perspective. *IEEE Transactions on Cybernetics*, 50(8), 3668-3681.
- Tuncera, E., & Bolat, E. D. (2022). Classification of epileptic seizures from electroencephalogram (EEG) data using bidirectional short-term memory (Bi-LSTM) network architecture. *Biomedical Signal Processing and Control*, 73, 103462.
- Wang, J., Li, X., Li, J., Sun, Q., & Wang, H. (2022). NGCU: A New RNN Model for Time-Series Data Prediction. *Big Data Research*, 27, 100296.
- Wood, D. A. (2020). Country-wide German hourly wind power dataset mined to provide insight to predictions and forecasts with optimized data-matching machine learning. *Renewable Energy Focus*, 34, 69-90.
- Xue, Q., & Chuah, M. C. (2018). New attacks on RNN based healthcare learning system and their detections. *Smart Health*, 9-10, 144-157.

- Yao, W., Huang, P., & Jia, Z. (2018) Multidimensional LSTM Networks to Predict Wind Speed. Chinese Control Conference, 37, 7493-7497.
- Zhang, Q., Zhang, J., Zou, J., & Fan, S. (2020). A Novel Fault Diagnosis Method based on Stacked LSTM. IFAC-PapersOnLine, 53(2), 790-795.

Application of LSTM for Renewable Energy Generation

Prediction - Solar Energy as an Example

Wang, Cheng-Hsiung

National Chin-Yi University of Technology, Department of Information Management
ch.weng@ncut.edu.tw

Chang, Ting-Yuan

National Chin-Yi University of Technology, Department of Information Management
c07408@ncut.edu.tw

Lu, Yu-Jia

National Chin-Yi University of Technology, Department of Information Management
louis880625@gmail.com

Abstract

To help electric power company to understand the power generation in advance and further effectively dispatch power and accurately grasp the real-time power generation information to reduce power loss and power generation cost consumption. There are 4 deep learning techniques (RNN, LSTM, Stack LSTM, and Bi-LSTM) are applied to solar power generation prediction in this study. We use the solar energy dataset collected by Alice Springs, Australia to build the 4 prediction models. There are 4 measures, named mean absolute error (MAE), mean square error (MSE), Root mean square error (RMSE) and R-squared (R^2) are used to evaluate the prediction performance of the four deep learning techniques. The experimental results show that: (1) RMSE and MSE metrics: Stack-LSTM model is the best; Bi-LSTM model is the second; LSTM model is the third; RNN is the worst. (2) MAE metrics: Bi-LSTM model is the best; Stack-LSTM model is the second; LSTM model is the third; RNN is the worst. (3) R^2 metrics: RNN model is the best; LSTM and Bi-LSTM models are the second; Stack-LSTM is the worst.

Keywords: Deep learning, solar power generation, RNN, LSTM, Stack LSTM, Bi-LSTM